Sebastián David Pinzón Zambrano

Data Engineer junior · Pipelines de datos reproducibles y ML aplicado

spinzonzambrano@gmail.com · linkedin.com/in/sebastiandpinzon · github.com/Ares-Infenus · Colombia (remoto o Bogotá)

PERFIL

Construyo pipelines de datos y modelos de machine learning en Python con una regla simple: cualquiera debe poder clonar el repositorio, correr los tests y llegar al mismo resultado. Mi trabajo público usa datos de mercados financieros: ingesta desde APIs, validación, almacenamiento en Parquet y Delta Lake, pipelines medallion con PySpark, feature engineering sin fuga de información y modelos servidos con FastAPI. Cada proyecto tiene tests, la mayoría CI y Docker, y su README dice qué funciona y qué no. Autodidacta, con experiencia gerencial y disciplina probada en entornos exigentes. Busco mi primer rol como Data Engineer junior o en equipos de datos y ML.

APTITUDES TÉCNICAS

Lenguajes y datos: Python, SQL, PostgreSQL, pandas, NumPy, Parquet
Ingeniería de datos: PySpark, Delta Lake, arquitectura medallion, ETL, validación de datos
ML: scikit-learn, XGBoost, SHAP, Optuna, Hugging Face, validación walk-forward
Ingeniería y entrega: Git, GitHub Actions (CI), Docker, pytest, FastAPI, Pydantic, Streamlit

PROYECTOS SELECCIONADOS (GITHUB.COM/ARES-INFENUS)

SparkFlow Delta Pipeline

PySpark · Delta Lake · Docker · GitHub Actions

Pipeline batch medallion (Bronze, Silver, Gold) para detección de fraude con reglas sobre transacciones bancarias sintéticas. Generador configurable hasta 100 M de filas (ejecutado a 100 k), particionado, compresión ZSTD, Z-ORDER y time travel; 24 tests y CI.

github.com/Ares-Infenus/SparkFlow_Delta_Pipeline

Alpha Feature Engineering

pandas · scikit-learn · statsmodels · pytest

Convierte datos OHLCV diarios en 77 features estacionarias por activo, diseñadas para evitar sesgo de anticipación. Capa de validación, transformadores compatibles con scikit-learn y diagnósticos con TimeSeriesSplit; 42 tests, con pruebas anti-fuga.

github.com/Ares-Infenus/alpha-feature-engineering-timeseries

Predictor de dirección BTC/USDT

XGBoost · Optuna · SHAP

Experimento con más de 28 000 velas horarias de Binance y validación walk-forward en 15 pliegues. ROC-AUC 0,543 ± 0,028: señal débil reportada como tal, no como estrategia; 98 tests.

github.com/Ares-Infenus/xgboost-financial-predictor

InsightFlow NLP

FastAPI · Hugging Face · spaCy · Docker

API REST con 8 endpoints (sentimiento, entidades y temas; lotes de hasta 500 textos) y tablero en Streamlit; ~170 ms por solicitud de sentimiento; 44 tests y CI.

github.com/Ares-Infenus/InsightFlow_NLP

Penguin Species API

FastAPI · Docker · Render

Servicio de ML desplegado con demo en vivo, validación estricta de entradas y pruebas de regresión contra un conjunto de referencia; 27 tests y CI.

github.com/Ares-Infenus/penguin-ml-api · Demo en vivo: penguin-ml-api-bmrr.onrender.com/docs

EXPERIENCIA

Colaborador junior de Machine Learning (voluntario) — Omdena oct. 2026 – actualidad

- Proyecto «GeoData Scout» con Humanitarian OpenStreetMap Team (HOT fAIr): investigación y preparación de datasets geoespaciales para modelos base de IA.

Auxiliar administrativo y de operaciones — Ejército Nacional de Colombia (servicio militar) ago. 2025 – actualidad

- Documentación oficial y abastecimiento de los pelotones; redacción y control documental de informes y reportes de novedades.
- Apoyo a la gestión administrativa de un pelotón en un entorno de alta disciplina y trabajo bajo presión.

Formación autodirigida en ciencia de datos y ML — Estudio independiente ago. 2024 – jul. 2025

- Programas de Stanford, DeepLearning.AI, Duke, IBM, Google, Johns Hopkins y University of Michigan en Python, SQL, MLOps y aprendizaje profundo.

Gerente general — Imperio del Plástico, Valledupar jun. 2023 – jun. 2024

- Dirección del negocio día a día: ventas, márgenes y resultado mensual en Excel, con tableros y gráficas.
- Proyección de ventas con líneas de tendencia y promedios móviles sobre el histórico; Python y SQL para limpiar y transformar datos contables y de ventas.
- Lanzamiento de una línea de fabricación de parrillas, rentable en su primer trimestre.

EDUCACIÓN Y CERTIFICACIONES

- **Universidad Nacional de Colombia** — Administración de Sistemas Informáticos, 2019–2023. Siete semestres cursados; programa no terminado.
- **14 certificaciones de Coursera**, entre ellas Machine Learning (Stanford), TensorFlow Developer y Deep Learning (DeepLearning.AI), MLOps (Duke), Google Data Analytics, IBM Data Science, Applied Data Science with Python y PostgreSQL for Everybody (University of Michigan).
- **Mejor resultado en las Pruebas Saber 11** — Secretaría de Educación Municipal, 2018.

IDIOMAS

Español: nativo. Inglés: nivel básico (A2), en estudio activo con meta B2.